

SIBINet Architecture Detailed Specification

Spesifikasi Detail Arsitektur SIBINet

By. Alfian Adi Pratama

May 28, 2026

Versi Bahasa Indonesia

1. Tinjauan Arsitektur SIBINet

SIBINet adalah arsitektur *Convolutional Neural Network* (CNN) ringan bergaya ResNet yang dirancang khusus untuk klasifikasi alfabet Sistem Isyarat Bahasa Indonesia (SIBI). Arsitektur ini menerima input berupa gambar RGB berukuran 128×128 piksel dan menghasilkan probabilitas klasifikasi untuk 24 kelas (A–Y, tanpa J dan Z). Model ini dirancang agar efisien dengan total parameter sekitar 2.1 juta, sehingga sangat optimal untuk inferensi *real-time*.

2. Komponen Utama Arsitektur

A. Blok *Stem* (Ekstraksi Fitur Awal)

Gambar input pertama kali diproses oleh blok *stem* yang terdiri dari lapisan konvolusi standar berukuran 3×3 dengan 32 filter (*stride* = 1, *padding* = 1), diikuti oleh *Batch Normalization* dan fungsi aktivasi ReLU. Proses ini diakhiri dengan *Max Pooling* 2×2 (*stride* = 2), yang berfungsi untuk mereduksi dimensi spasial fitur dari 128×128 menjadi 64×64 .

B. *ResLiteBlock* dan *Depthwise Separable Convolution*

Inti dari SIBINet adalah penggunaan **ResLiteBlock**, sebuah blok residual ringan yang dibangun menggunakan *Depthwise Separable Convolution* (DSCConv). DSCConv memecah konvolusi standar menjadi dua tahap:

1. **Depthwise Convolution:** Mengaplikasikan filter 3×3 secara terpisah pada setiap saluran (*channel*) input.
2. **Pointwise Convolution:** Mengaplikasikan filter 1×1 untuk menggabungkan *channel* keluaran dari tahap sebelumnya.

Pendekatan ini secara signifikan memangkas beban komputasi dan jumlah parameter model. Selain itu, terdapat koneksi residual (*skip connection*) yang menambahkan fitur input asli ke output konvolusi, untuk mencegah terjadinya degradasi gradien pada jaringan yang dalam.

C. Tahapan Jaringan (*Stages 1–4*)

Setelah blok *stem*, jaringan dibagi menjadi empat tahapan progresif, di mana masing-masing tahap terdiri dari 2 *ResLiteBlock*:

- **Stage 1:** Meningkatkan kedalaman *channel* dari 32 ke 64, sambil mereduksi dimensi spasial menjadi 32×32 melalui *stride* 2 pada blok pertama.
- **Stage 2:** *Channel* meningkat menjadi 128, dan dimensi spasial menjadi 16×16 .
- **Stage 3:** *Channel* meningkat menjadi 256, dan dimensi spasial menjadi 8×8 .
- **Stage 4:** *Channel* mencapai puncaknya di 512, dan dimensi spasial menjadi 4×4 .

D. *Classification Head*

Tahap akhir jaringan menggunakan *Adaptive Average Pooling* untuk merangkum peta fitur spasial 4×4 menjadi vektor 1D berukuran 512. Vektor ini kemudian dilewatkan pada lapisan *Dropout* (dengan probabilitas $p = 0.4$) untuk mencegah *overfitting*, sebelum akhirnya diproses oleh lapisan *Fully Connected* (Linear) untuk menghasilkan *logits* akhir bagi 24 kelas.

English Version

1. SIBINet Architecture Overview

SIBINet is a lightweight, ResNet-style Convolutional Neural Network (CNN) specifically tailored for Indonesian Sign Language (SIBI) alphabet classification. The architecture accepts 128×128 pixel RGB images as input and outputs classification probabilities for 24 distinct classes (A–Y, excluding J and Z). Engineered for efficiency, the model contains approximately 2.1 million parameters, making it highly optimal for real-time inference.

2. Core Architectural Components

A. Stem Block (Initial Feature Extraction)

The input image is initially processed by a stem block consisting of a standard 3×3 convolutional layer with 32 filters (stride = 1, padding = 1), followed by Batch Normalization and a ReLU activation function. This process concludes with a 2×2 Max Pooling operation (stride = 2), which reduces the spatial dimensions of the feature map from 128×128 to 64×64 .

B. ResLiteBlock and Depthwise Separable Convolution

The core building block of SIBINet is the **ResLiteBlock**, a lightweight residual block constructed using Depthwise Separable Convolutions (DSConv). DSConv decomposes a standard convolution into two distinct stages:

1. **Depthwise Convolution:** Applies a 3×3 filter independently to each input channel.
2. **Pointwise Convolution:** Applies a 1×1 filter to linearly combine the output channels from the previous stage.

This approach drastically reduces computational cost and parameter count. Additionally, a residual skip connection adds the original input features to the convolutional output, mitigating the vanishing gradient problem in deeper networks.

C. Network Stages (Stages 1–4)

Following the stem block, the network is divided into four progressive stages, each containing 2 ResLiteBlocks:

- **Stage 1:** Increases channel depth from 32 to 64 while reducing spatial dimensions to 32×32 via a stride of 2 in the first block.
- **Stage 2:** Channels increase to 128, spatial dimensions reduce to 16×16 .

- **Stage 3:** Channels increase to 256, spatial dimensions reduce to 8×8 .
- **Stage 4:** Channels reach 512, spatial dimensions reduce to 4×4 .

D. Classification Head

The final stage employs an Adaptive Average Pooling layer to collapse the 4×4 spatial feature maps into a 1D vector of length 512. This vector is then passed through a Dropout layer (with probability $p = 0.4$) to prevent overfitting, before being processed by a Fully Connected (Linear) layer to produce the final logits for the 24 classes.